Deep learning par la pratique

Leçon 1 : introduction

Présenté par **Morgan Gautherot**

Pourquoi des modèles de séquence ?

	X		Y
Reconnaissance vocale	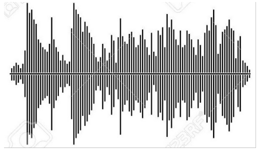	→	“Never stoop learning”
Génération de musique	∅	→	
Classification des sentiments	“There is nothing to like in this movie.”	→	
Analyse des séquences d'ADN	AGCCCCTGTGAGGAACTAG	→	AGCCCCTGTGAGGAACTAG
Traduction automatique	Artificial Intelligence is the New Electricity	→	L'intelligence artificielle est la nouvelle électricité
Reconnaissance d'activité		→	Running
Reconnaissance d’un nom	Elon Musk is the founder of SpaceX	→	Elon Musk is the founder of SpaceX

Notation

Reconnaissance de nom

x: “Harry Potter and Hermione Granger invented a new spell.”

$x^{<1>}$ $x^{<2>}$ $x^{<3>}$ … $x^{<t>}$ … $x^{<8>}$ $x^{<9>}$

y: [1 , 1 , 0 , 1 , 1 , 0 , 0 , 0 , 0]

$y^{<1>}$ $y^{<2>}$ $y^{<3>}$ … $y^{<t>}$ … $y^{<9>}$

$X^{(i)<t>}$ observation de la séquence t du $i^{ème}$ exemple.

$y^{(i)<t>}$ target de la séquence t du $i^{ème}$ exemple.

${T_x}^{(i)}$ est la longueur de la séquence d'observations.

${T_y}^{(i)}$ est la longueur de la séquence des valeurs cibles.

Pourquoi pas un réseau dense ?

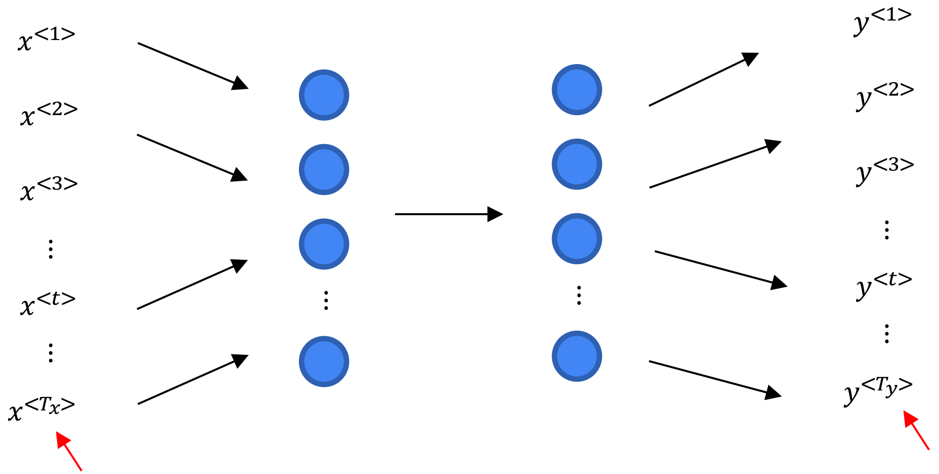

Problèmes :

- Les entrées et les sorties peuvent être de longueurs différentes dans différents exemples.

- Ne partage pas les caractéristiques apprises entre les différentes positions de la séquence.

Deep learning par la pratique

Leçon 2 : Le recurrent Neural Network (RNN)

Présenté par **Morgan Gautherot**

Recurrent Neural Networks

Ici $T_x = T_y$

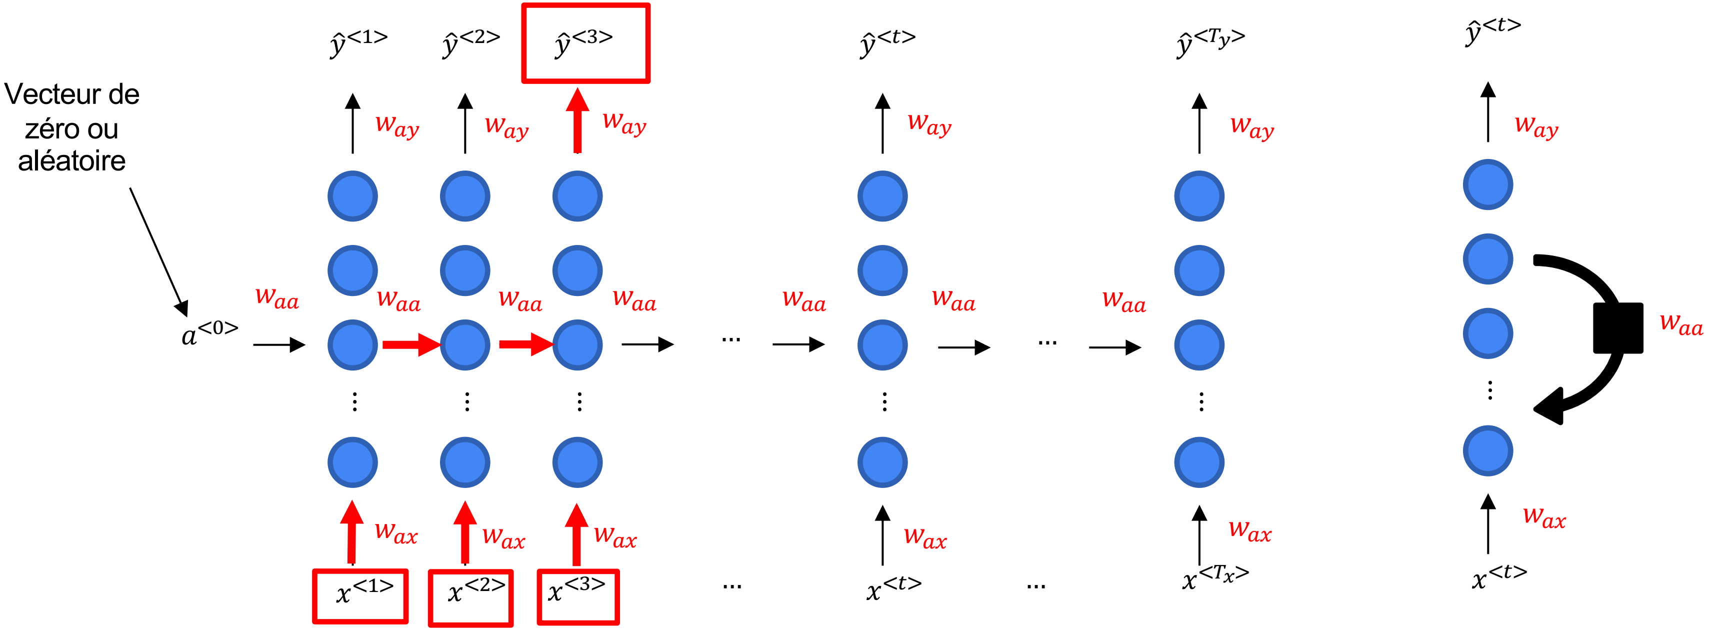

Deep learning par la pratique

Leçon 2 : Le recurrent Neural Network (RNN)

Présenté par **Morgan Gautherot**

Forward propagation

Here $T_x = T_y$

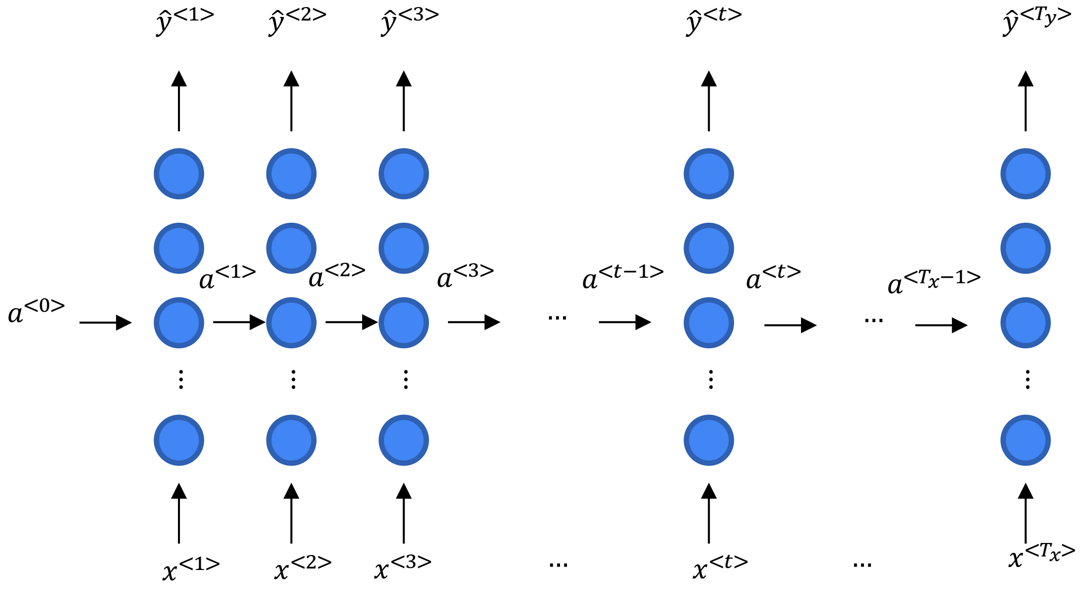

$$a^{<0>} = \vec{0}$$

$$a^{<1>} = g(W_{aa}a^{<0>} + W_{ax}x^{<1>} + b_a) \longleftarrow \text{Relu}$$

$$\hat{y}^{<1>} = \sigma(W_{ya}a^{<1>} + b_y) \longleftarrow \text{Sigmoid}$$

$$a^{<t>} = g(W_{aa}a^{<t-1>} + W_{ax}x^{<t>} + b_a)$$

$$\hat{y}^{<t>} = \sigma(W_{ya}a^{<t>} + b_y)$$

Notation

$a^{<t>} = g(W_{aa}a^{<t-1>} + W_{ax}x^{<t>} + b_a)$

$\hat{y}^{<t>} = g(W_{ya}a^{<t>} + b_y)$

W_a=$[W_{aa}, W_{ax}]$

$a^{<t>} = g(W_a[a^{<t-1>}, x^{<t>}] + b_a)$

$\hat{y}^{<t>} = g(W_y a^{<t>} + b_y)$

$[W_{aa}, W_{ax}] \begin{bmatrix} a^{<t-1>} \\ x^{<t>} \end{bmatrix} = W_{aa}a^{<t-1>} + W_{ax}x^{<t>}$

Fonction de coût

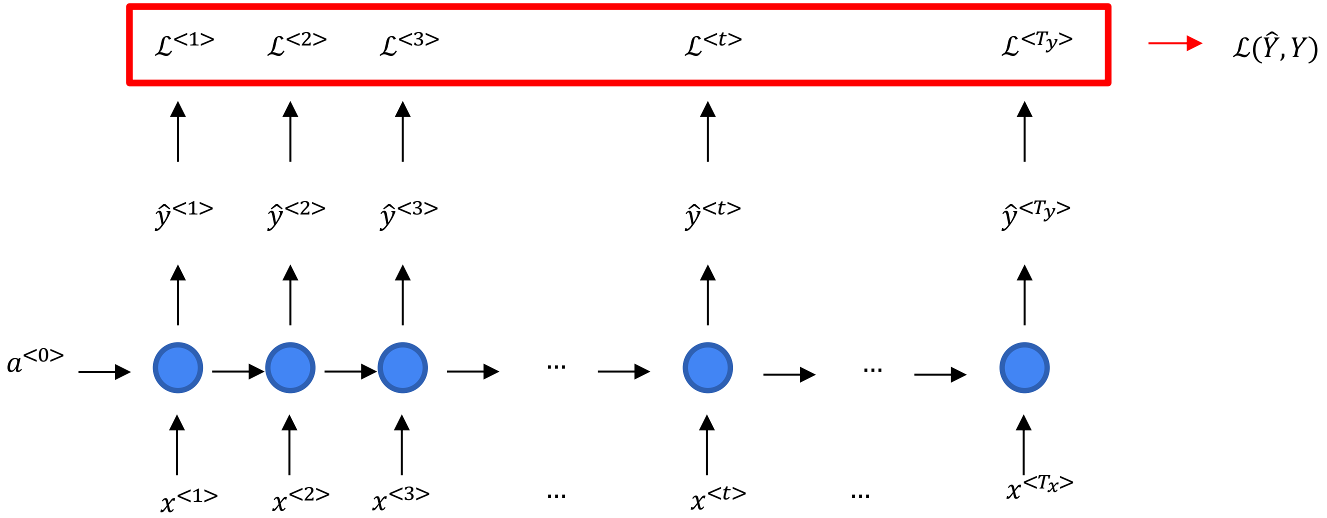

$$\mathcal{L}^{<t>}(\hat{y}^{<t>}, y^{<t>}) = -y^{<t>} \log(\hat{y}^{<t>}) - (1 - y^{<t>}) \log((1 - \hat{y}^{<t>})$$

$$\mathcal{L}(\hat{y}, y) = \sum_{t=1}^{T_y} \mathcal{L}^{<t>}(\hat{y}^{<t>}, y^{<t>})$$

Backpropagation

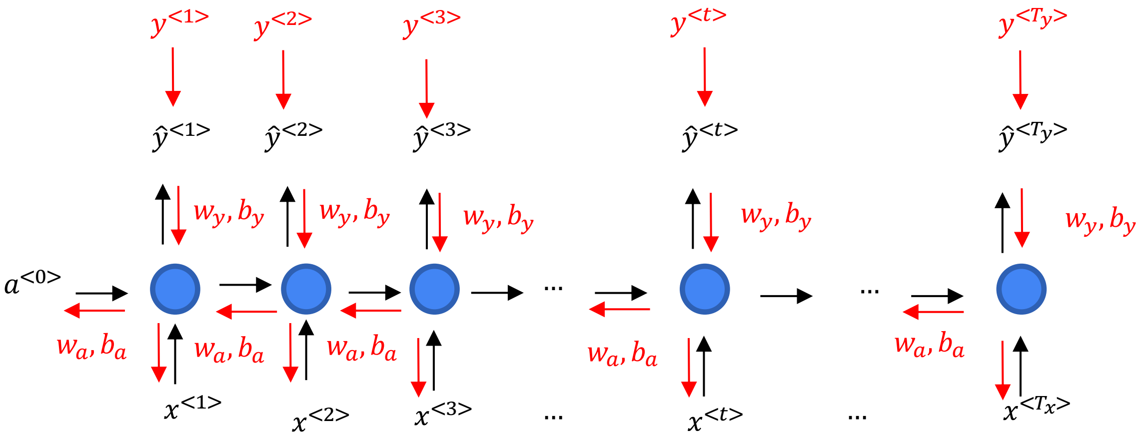

Deep learning par la pratique

Leçon 3 : Les différentes architectures

Présenté par **Morgan Gautherot**

Many to many

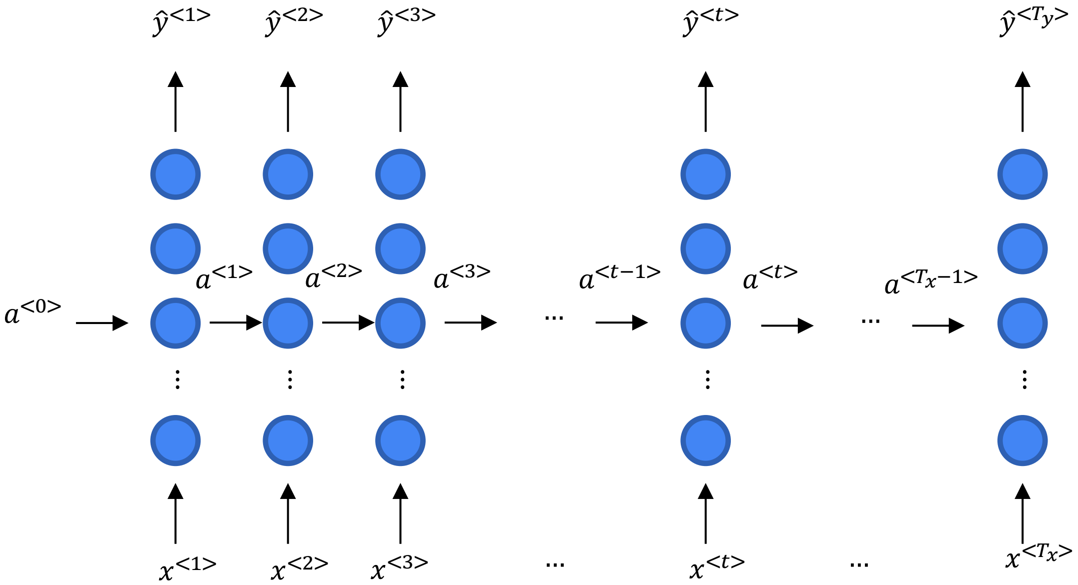

$T_x = T_y$

Many to many

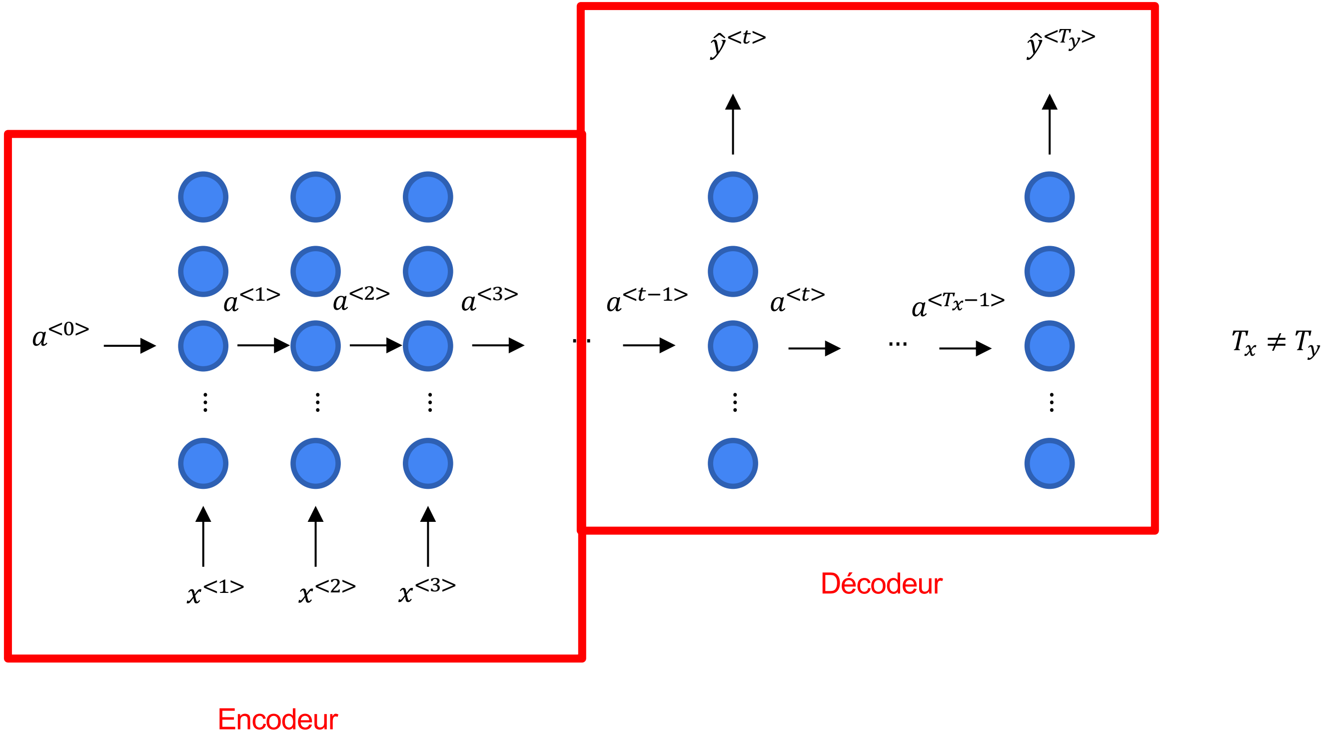
$\hat{y}^{<t>}$
$\hat{y}^{<T_y>}$
$a^{<0>}$
$a^{<1>}$
$a^{<2>}$
$a^{<3>}$
$a^{<t-1>}$
$a^{<t>}$
$a^{<T_x-1>}$
$x^{<1>}$
$x^{<2>}$
$x^{<3>}$
Décodeur
Encodeur
$T_x \neq T_y$

Many to one

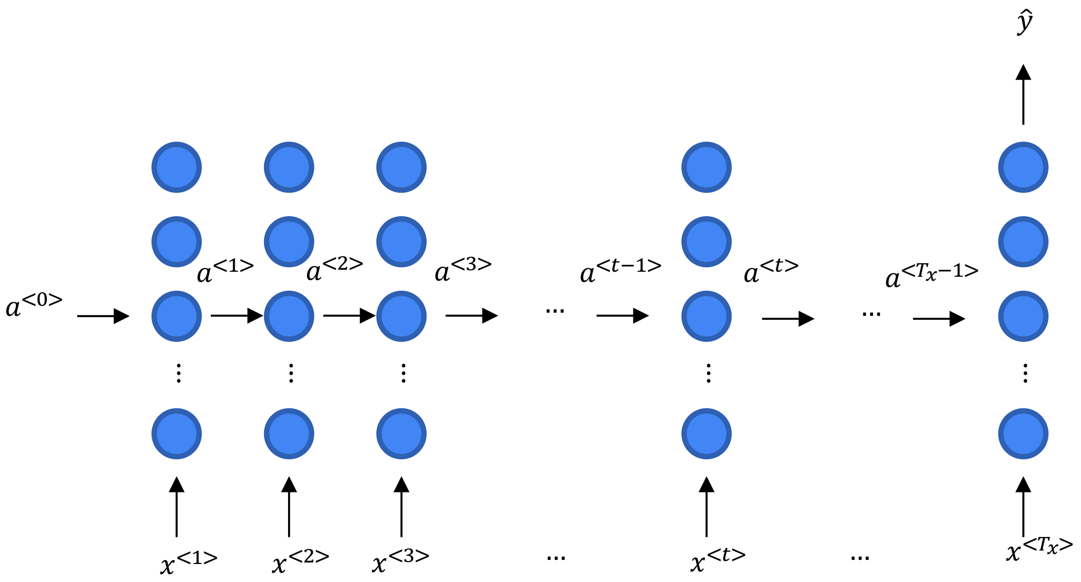

$T_x \neq T_y$

One to many

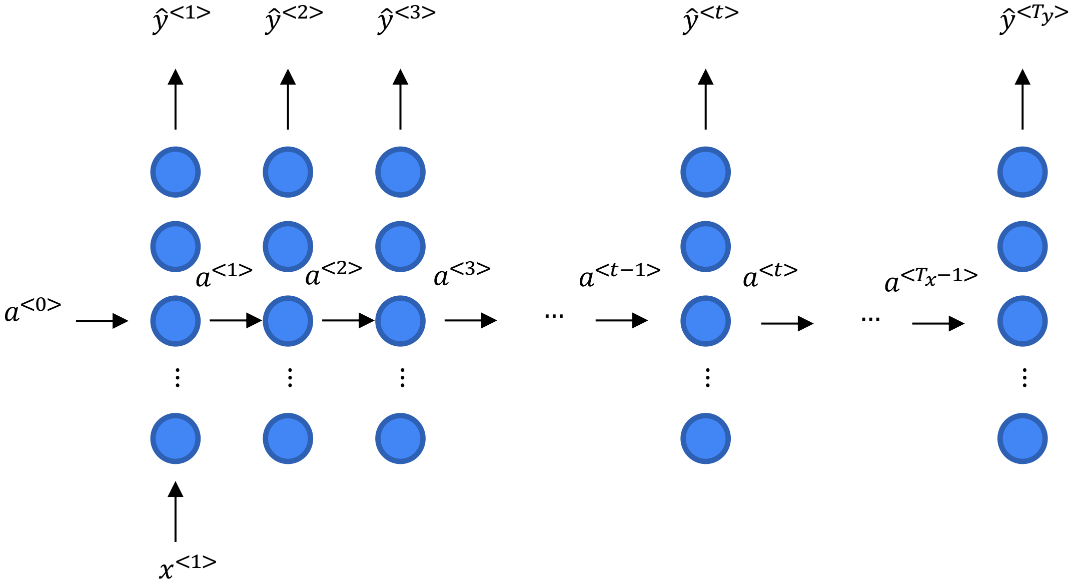

$T_x \neq T_y$

One to many

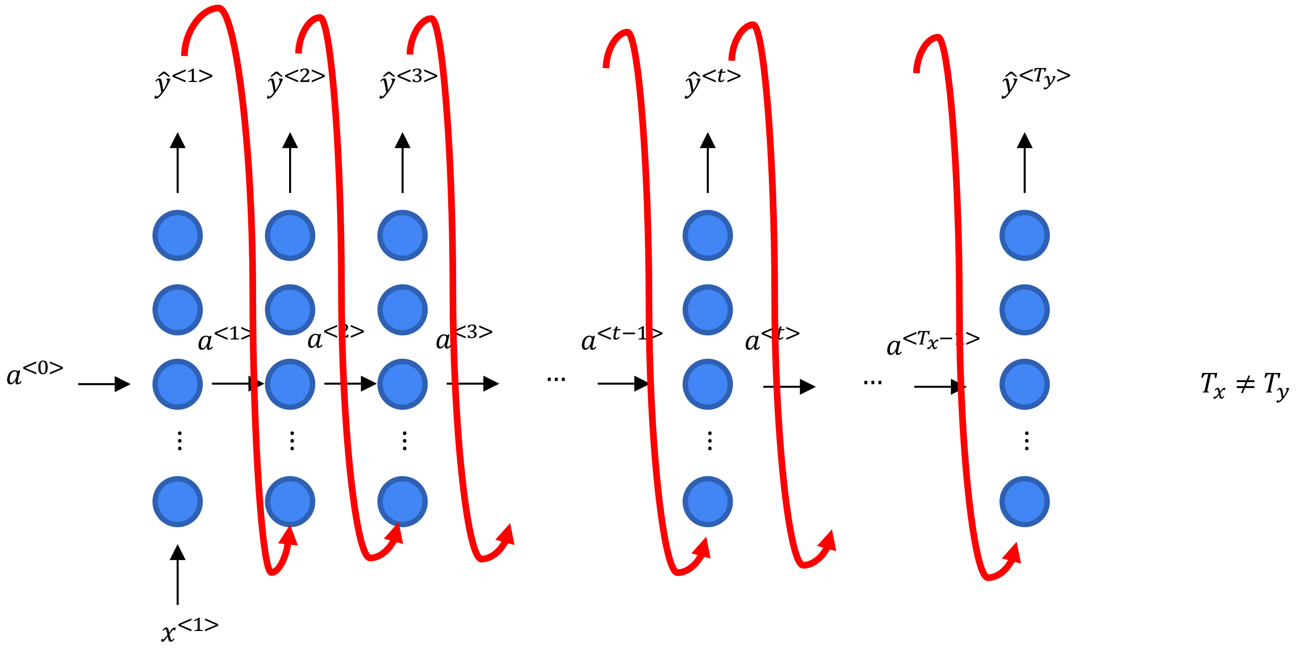
$\hat{y}^{<1>}$
$\hat{y}^{<2>}$
$\hat{y}^{<3>}$
$\hat{y}^{<t>}$
$\hat{y}^{<T_y>}$
$a^{<0>}$
$a^{<1>}$
$a^{<2>}$
$a^{<3>}$
...
$a^{<t-1>}$
$a^{<t>}$
...
$a^{<T_x-1>}$
$x^{<1>}$
$T_x \neq T_y$

Deep learning par la pratique

Leçon 4 : Bidirectional RNN (BRNN)

Présenté par **Morgan Gautherot**

De l’information manquantes

He said, “Teddy Roosevelt was a great President.”

He said, “Teddy bears are on sale!”

Bidirectional RNN (BRNN)

$$\hat{y}^{<t>} = g(w_y[a_1{}^{<t>}, a_2{}^{<t>}] + b_y)$$

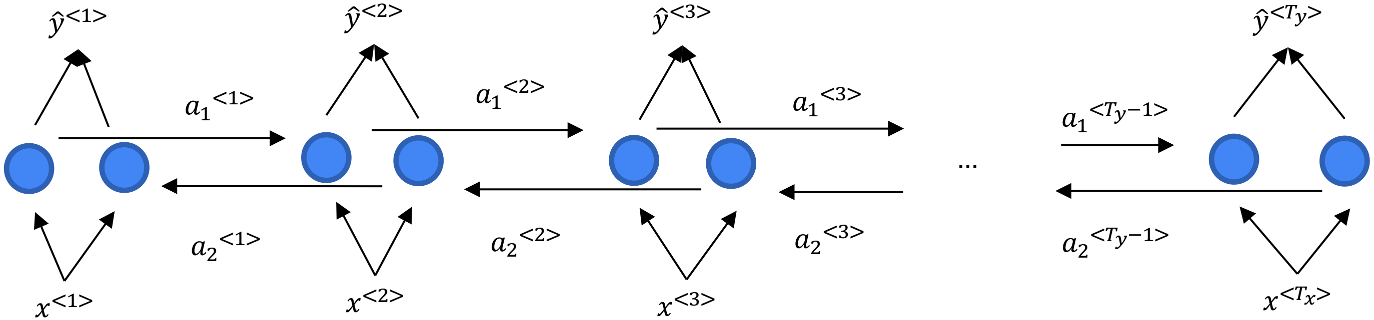

Deep learning par la pratique

Leçon 4 : Deep RNN

Présenté par **Morgan Gautherot**

Deep RNN

couche

temps

$$a^{[l]<t>}$$

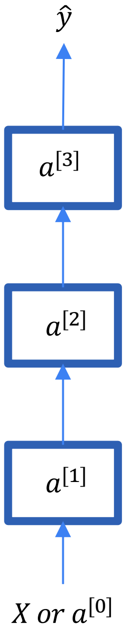

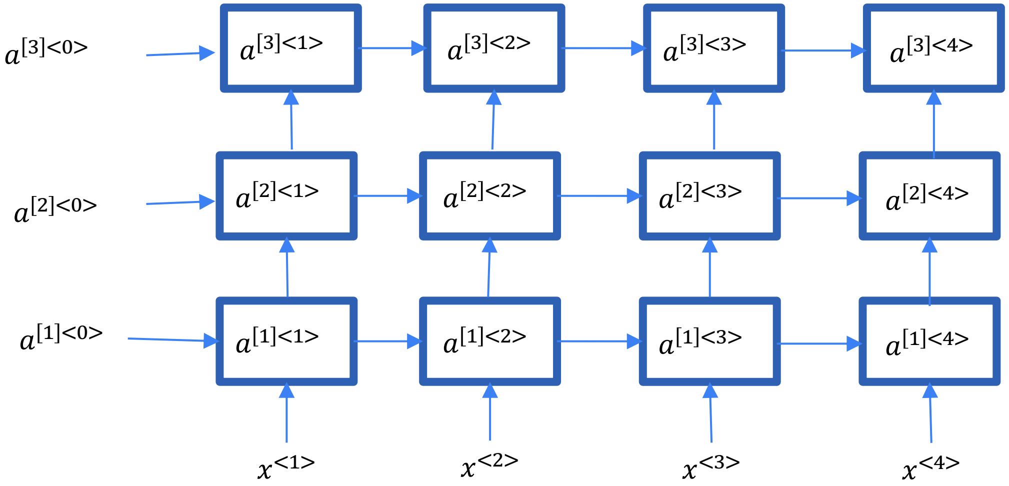

Deep learning par la pratique

Leçon 5 : Problème de mémoire

Présenté par **Morgan Gautherot**

Le problème du RN classique

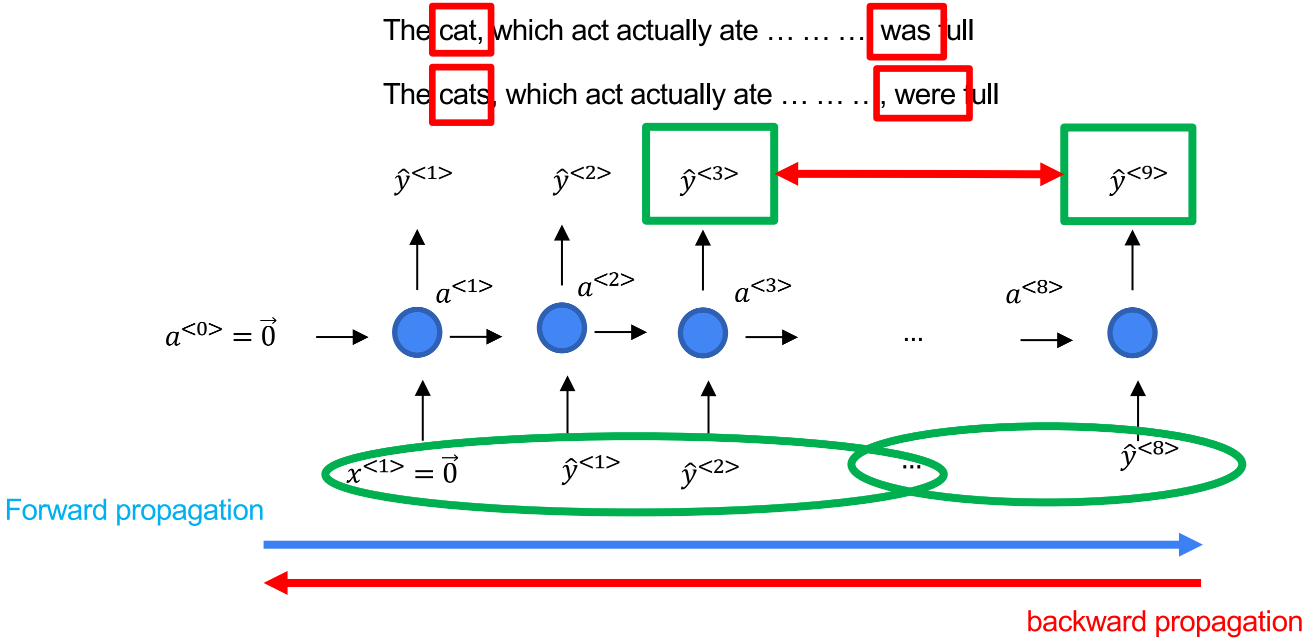

L'influence des premiers termes

I like to study machine learning ________________

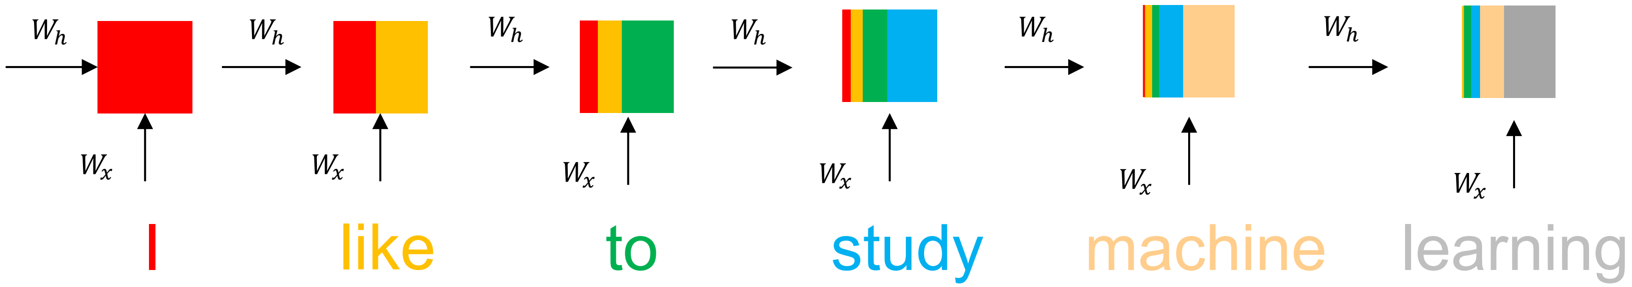

Deep learning par la pratique

Leçon 7 : Le Gate Recurrent Unit (GRU)

Présenté par **Morgan Gautherot**

Recurrent Neural Network

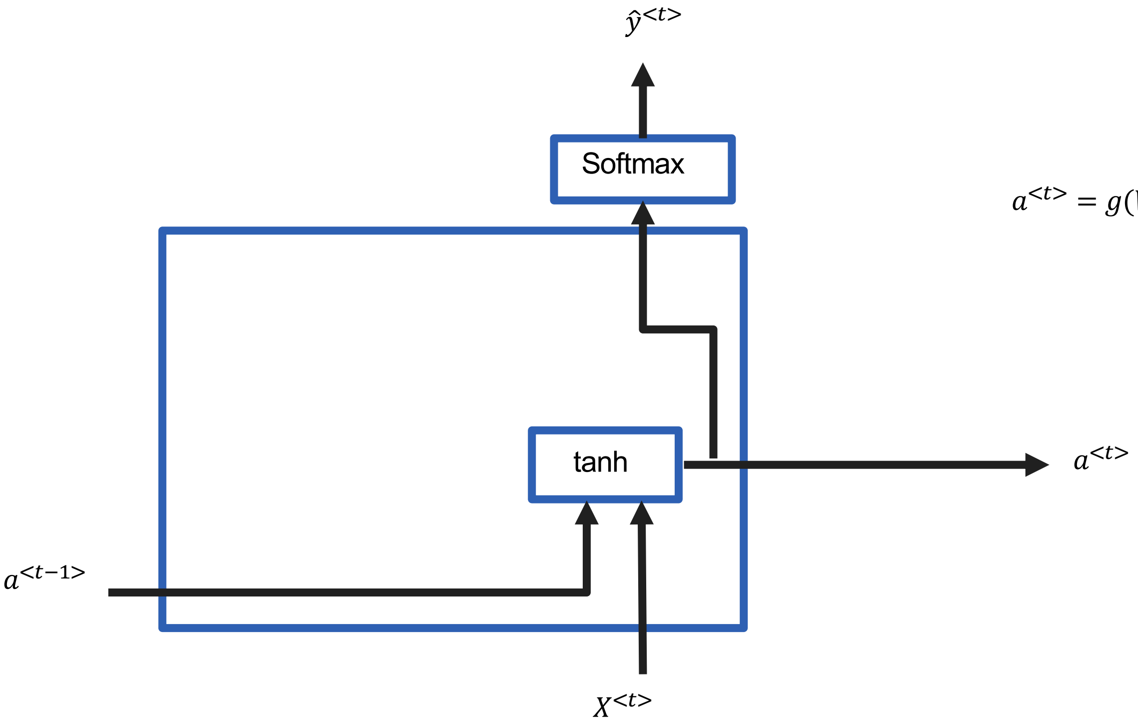

$$a^{<t>} = g(W_a[a^{<t-1>}, x^{<t>}] + b_a)$$

Gate Recurrent Unit (GRU) (simplified)

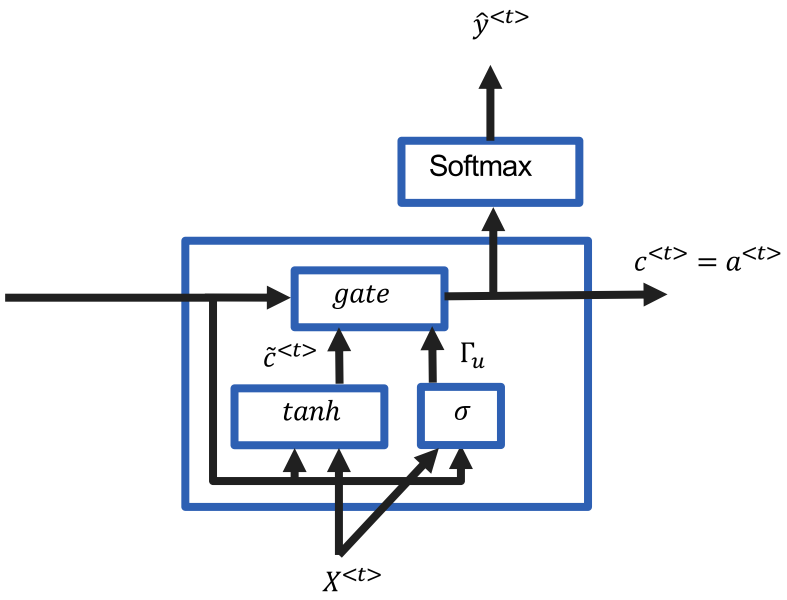

σ est la fonction sigmoïd

c = unité de mémoire

$c^{<t>} = a^{<t>}$

$\tilde{c}^{<t>} = \tanh(w_c[c^{<t-1>}, X^{<t>}] + b_c$

$\Gamma_u = \sigma(w_u[c^{<t-1>}, X^{<t>}] + b_u)$

$0 < \Gamma_u < 1$

$c^{<t>} = \Gamma_u * \tilde{c}^{<t>} + (1 - \Gamma_u) * c^{<t-1>}$

Gate Recurrent Unit (GRU)

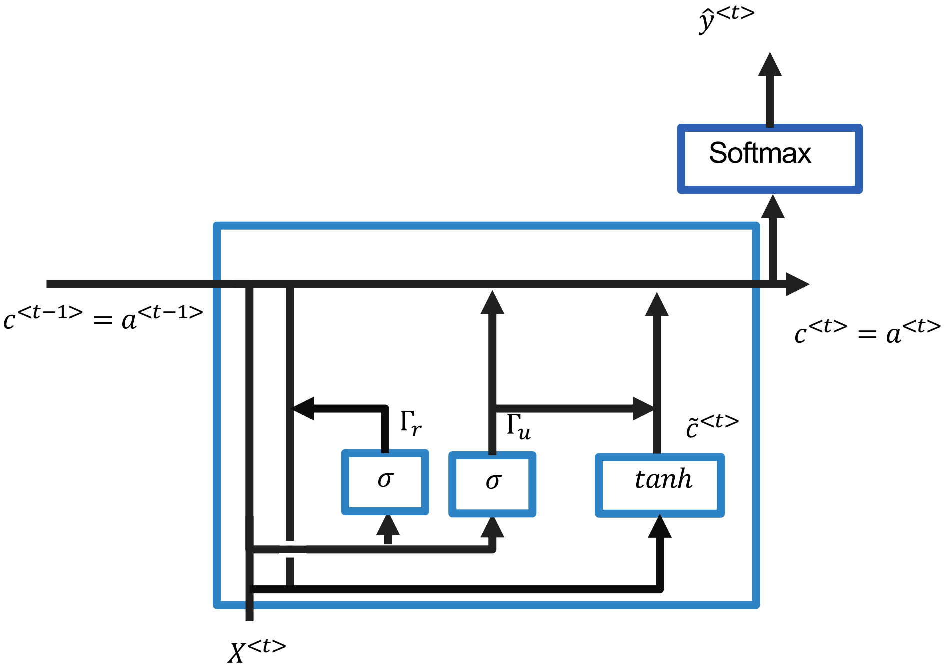

c = unité de mémoire

$c^{<t>} = a^{<t>}$

$\tilde{c}^{<t>} = \tanh(w_c[\Gamma_r * c^{<t-1>}, X^{<t>}] + b_c$

$\Gamma_u = \sigma(w_u[c^{<t-1>}, x^{<t>}] + b_u)$

$\Gamma_r = \sigma(w_r[c^{<t-1>}, x^{<t>}] + b_r)$

$c^{<t>} = \Gamma_u * \tilde{c}^{<t>} + (1 - \Gamma_u) * c^{<t-1>}$

Deep learning par la pratique

Leçon 7 : Le Gate Recurrent Unit (GRU)

Présenté par **Morgan Gautherot**

Recurrent Neural Network

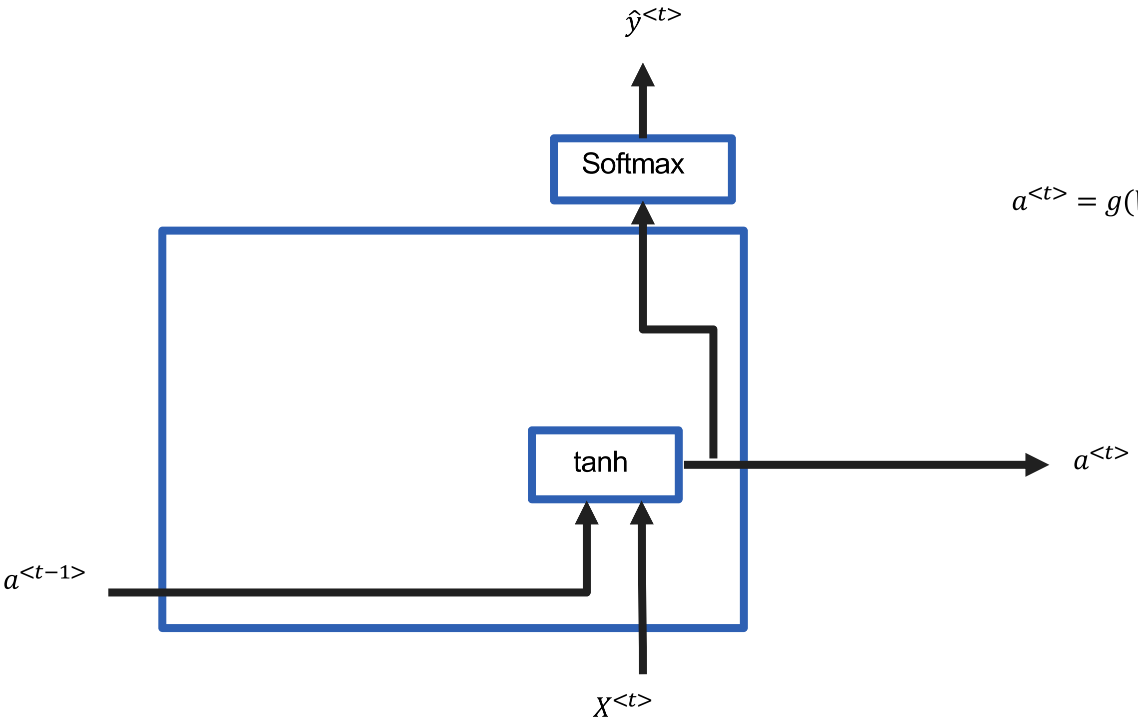

$$a^{<t>} = g(W_a[a^{<t-1>}, x^{<t>}] + b_a)$$

Gate Recurrent Unit and Long Short Term Memory

GRU

$$\tilde{c}^{<t>} = \tanh(w_c[\Gamma_r * c^{<t-1>}, X^{<t>}\} + b_c$$

$$\Gamma_u = \sigma(w_u[c^{<t-1>}, x^{<t>}] + b_u)$$

$$\Gamma_r = \sigma(w_r[c^{<t-1>}, x^{<t>}] + b_r)$$

$$c^{<t>} = \Gamma_u * \tilde{c}^{<t>} + (1 - \Gamma_u) * c^{<t-1>}$$

LSTM

$$\tilde{c}^{<t>} = \tanh(w_c[a^{<t-1>}, X^{<t>}\} + b_c$$

$$\Gamma_u = \sigma(w_u[a^{<t-1>}, x^{<t>}] + b_u)$$

$$\Gamma_f = \sigma(w_f[c^{<t-1>}, x^{<t>}] + b_f)$$

$$\Gamma_o = \sigma(w_o[c^{<t-1>}, x^{<t>}] + b_o)$$

$$c^{<t>} = \Gamma_u * \tilde{c}^{<t>} + \Gamma_f * c^{<t-1>}$$

$$a^{<t>} = \Gamma_0 * \tanh(c^{<t>})$$

Long Short Term Memory (LSTM)

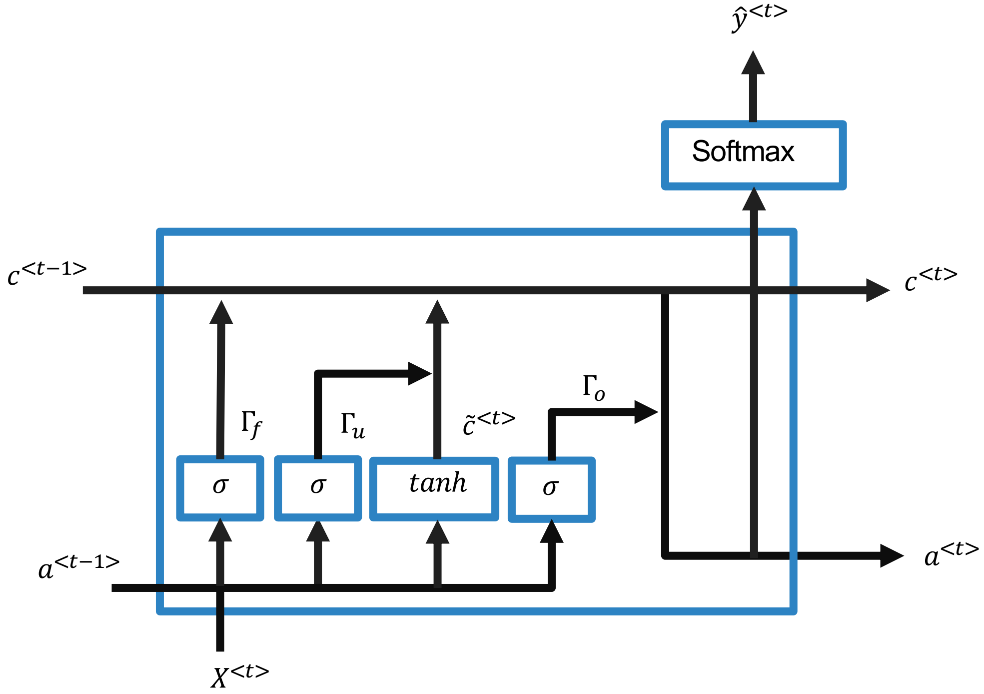

$$\tilde{c}^{<t>} = \tanh(w_c[a^{<t-1>}, X^{<t>}\} + b_c$$

$$\Gamma_u = \sigma(w_u[a^{<t-1>}, x^{<t>}] + b_u)$$

$$\Gamma_f = \sigma(w_f[a^{<t-1>}, x^{<t>}] + b_f)$$

$$\Gamma_o = \sigma(w_o[a^{<t-1>}, x^{<t>}] + b_o)$$

$$c^{<t>} = \Gamma_u * \tilde{c}^{<t>} + \Gamma_f * c^{<t-1>}$$

$$a^{<t>} = \Gamma_0 * \tanh(c^{<t>})$$

LSTM en série